

Tema 02. Clasificación y Regresión


(Parte 3: Clasificación)

Autor: Ismael Sagredo Olivenza


2.3. Clasificación

- Hasta ahora, hemos estimado el valor de una variable basándonos en el valor de sus características
- Pero hay otro tipo de problemas en los que intentamos deducir a partir de los datos de entrada de qué tipo de ejemplo se trata, por ejemplo: si una imagen es un gato o un perro, si un correo electrónico es spam o no, etc.
- En este caso, no esperamos una salida continua y queremos aproximarnos a ella.
- Esperamos una salida discreta

Classification: Breast cancer detection




En este tipo de problemas no podemos aplicar regresión lineal, ya que la aproximación que realiza es muy mala como podemos ver en el siguiente ejemplo.



2.3.1 Logistic regression

Debemos aplicar la regresión logística. Esta regresión se basa en la función logística: $g(z) = \frac{1}{1+e^{-z}}$

La salida debe estar entre 0 y 1.



2.3.1 Función a optimizar




- z es un parámetro que nos determina la familia de funciones logísticas que podemos crear. Podemos combinar la función logística con la recta de regresión. El resultado es que seguimos teniendo los mismos parámetros w y b , pero aplicados a la función logística.

$$f_{\vec{w},b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w}\vec{x}+b)}}$$

- La salida representa la probabilidad de que un ejemplo pertenezca a una clase o a otra. $F(X) = 0.7$ representa una probabilidad del 70% de tener cancer, en el dominio del cancer de mama.

2.3.2 Frontera de decisión

- La función con parámetros que pongamos en Z , nos permite seleccionar como vamos a dividir las dos clases. Ej: en las siguientes imágenes tenemos una par de rectas y un círculo como frontera



2.3.3 Función de coste


- Seguimos usando la misma medida del error:

$$J(\vec{w}, b) = \frac{1}{2m} \cdot \sum_{i=1}^m (f_{\vec{w},b}(\vec{x}_i) - y_i)^2$$

- Pero la función: $f_{\vec{w},b}(\vec{x}_i)$ es diferente.
- **Loss:** es un valor que representa la suma de los errores de nuestro modelo. Mide lo bien (o mal) que lo está haciendo nuestro modelo.


linear regression

$$f_{\vec{w},b}(\vec{x}) = \vec{w} \cdot \vec{x} + b$$



logistic regression

$$f_{\vec{w},b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$





Si la función $J(\vec{w}, b)$ es convexa podemos alcanzar el mínimo global.
Pero en otras funciones (la logistica por ejemplo) es más complejo

2.3.3.1 Logistic function Loss (L)

Vamos a volver la función logística convexa con un truco:

- If $y_i = 1 \Rightarrow L(f_{\vec{w},b}(\vec{x}_i)) = -\text{Log}(f_{\vec{w},b}(\vec{x}_i))$
- if $y_i = 0 \Rightarrow L(f_{\vec{w},b}(\vec{x}_i)) = -\text{Log}(1 - f_{\vec{w},b}(\vec{x}_i))$
- Al transformar la función loss siempre es convexa



2.3.3.2 Simplificamos la función de coste de esta forma:

$$J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m L[(f_{\vec{w},b}(\vec{x}_i), y_i]$$

$$J(\vec{w}, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(y'_i) + (1 - y_i) \log(1 - y'_i)]$$

Donde

$$y' = f_{\vec{w},b}(\vec{x}_i) = \frac{1}{1 + e^{-(\vec{w}\vec{x}+b)}}$$

2.3.4 ¿Cómo sería el descenso de gradiente?

Si derivamos J vemos que el resultado es el mismo que en la regresión normal (recordad: $f(x) = \log_a(x)$, $f'(x) = \frac{1}{x \cdot \ln(a)}$)

$$w_j = w_j - \alpha \frac{1}{m} \sum_{i=1}^m y'_i - y_i x_{j,i}$$

$$b = b - \alpha \frac{1}{m} \sum_{i=1}^m y'_i - y_i$$

Donde: $y' = f_{\vec{w},b}(\vec{x}_i) = \frac{1}{1+e^{-(\vec{w}\vec{x}+b)}}$

2.3.5 Multiclass classification

Aplicamos 1 clase frente a todas las demás para cada una de las clases calculando su probabilidad.

Para una nueva entrada x , para realizar una predicción, habrá que encontrar la clase que maximice la función:

$$\text{Max}(f_{\vec{w},b}^i(\vec{x})) \forall i \in \text{Class}$$

En otras palabras, hay que aplicar tantas regresiones logisticas como clases tengamos y quedarnos con la predicción de aquella regresión logistica que tenga mayor valor (será la más probable)

Ejemplo:

Tenemos 3 clases, Alto, Medio, Bajo.

Podemos calcular la regresión logística para Alto Vs ElResto. Donde el resto serían las clases medio y bajo. Después podemos calcular la regresión logística para las clases Medio Vs ElResto (Alto y Bajo). Y por último podríamos calcular la regresión logística para la clase Bajo, frente a el ElResto (alto y medio)

¿Cuál sería al clase a elegir? aquell que tenga una probabilidad más alta.

2.3.6 Overfitting

Si tenemos muchas características, el modelo puede adaptarse muy bien a los datos de entrenamiento, pero no ajustarse correctamente a nuevos ejemplos.

Soluciones al sobreajuste, reducir el número de características:

- Selección manual de características o algoritmo de selección
- Regularización: Mantiene todas las características, pero reduce la magnitud o los valores de los parámetros. Funciona con muchas características

2.4. Regularización


Es una técnica utilizada en el aprendizaje automático para evitar el sobreajuste de los modelos.

Un modelo se ajusta demasiado a los datos de entrenamiento y pierde capacidad de generalización.


Regularizar los modelos nos ayuda a reducir su complejidad y evitar el sobreajuste.

2.4.1 Sobreajuste y cómo abordarlo

- Recopilar más ejemplos de entrenamiento
- Seleccionar características manualmente o mediante un algoritmo
=> podrían perderse características útiles
- Regularización => reducir el tamaño de ciertos parámetros de W



$$f(x) = 28x - 385x^2 + 39x^3 - 174x^4 + 100$$



$$f(x) = 13x - 0.23x^2 + 0.000014x^3 - 0.000x^4 + 10$$

La regularización realiza una pesimización de los modelos, con la esperanza de que estos no se sobreajusten demasiado e los datos de entrenamiento.

Ventajas

- Mantiene todas las características, pero reduce la magnitud de los parámetros
- Funciona bien cuando tenemos muchas características, cada una de las cuales contribuye un poco a la predicción
- Es necesario reducir la varianza y aumentar el sesgo.
- No siempre es aplicable, por lo que en la práctica depende de un parámetro λ que la regula.

2.4.3 Cost Function con regularización

- La intuición es reducir los pesos para reducir la complejidad del modelo
- Imaginemos que una regresión lineal ha generado el siguiente modelo

$$w_1x + w_2x^2 + w_3x^3 + w_4x^4 + b$$

- pero el mejor modelo es

$$w_1x + w_2x^2 + b$$

Necesitamos minimizar w_3 y w_4 a valores cercanos a cero

Para reducir la función de coste añadimos una función de penalización $p(w)$ to $J(\vec{w}, b)$

Utilizamos $\lambda > 0$ como tasa de aprendizaje. El parámetro es un hiperparámetro del modelo (similar a α en el descenso gradiente)

$$\min J(w, b) = \min \left(\frac{1}{2m} \cdot \sum_{i=1}^m (y_i' - y_i)^2 + \lambda p(w) \right)$$

$$y' = f_{w,b}(x_i)$$

Hay dos tipos de regularización que podemos aplicar ,al regularización L1 y L2.

2.4.4 Regularización L1 (Lasso)

La regularización L1 añade una función de penalización proporcional a la suma en valor absoluto de los coeficientes del modelo.

$$p(w) = \sum_{j=1}^m |w_j|$$

- Esto tiene como efecto forzar a que algunos coeficientes sean cero.

2.4.5 Regularización L2 (Ridge)

La regularización L2 añade un término de penalización proporcional a la suma de los cuadrados de los coeficientes del modelo.

$$p(w) = \sum_{j=1}^m w_j^2$$

- Esto tiene el efecto de reducir los valores de los coeficientes, lo que puede ayudar a evitar el sobreajuste, pero nunca llegarán a ser cero.
- L2 es la mas usada en la práctica.

2.4.6 Regularization en regresión lineal (L2)

$$J(w, b) = \frac{1}{2m} \cdot \sum_{i=1}^m (y'_i - y_i)^2 + \frac{\lambda}{2m} \sum_{j=1}^n w_j^2$$

Descenso de gradiente, igual pero la derivada sería:

$$\frac{\partial J(w, b)}{\partial w_j} = \left[\frac{1}{m} \cdot \sum_{i=1}^m (y'_i - y_i) \cdot x_j + \frac{\lambda}{m} w_j \right] \forall j$$

$$\frac{\partial J(w, b)}{\partial b} = \frac{1}{m} \cdot \sum_{i=1}^m (y'_i - y_i)$$

$$w = w_j - \alpha \frac{\partial J(w, b)}{\partial w_j}$$

$$b = b - \alpha \frac{\partial J(w, b)}{\partial b}$$

Donde n = número de características y m = número de ejemplos y

$$y' = f_{\vec{w}, b}(\vec{x}_i) = \vec{w}\vec{x} + b$$

2.4.7 Regularización en regresión logística

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(y'_i) + (1 - y_i) \log(1 - y'_i)] + \frac{\lambda}{2m} \cdot \sum_{j=1}^n (w_j^2)$$

Descenso de gradiente, igual pero la derivada sería:

$$\frac{\partial J(w, b)}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m (y'_i - y_i) \cdot x_j + \frac{\lambda}{m} \cdot w_j \forall j$$

$$\frac{\partial J(w, b)}{\partial b} = \frac{1}{m} \cdot \sum_{i=1}^m (y'_i - y_i)$$